Admissão em MBA: o que separa os candidatos aprovados

Análise exploratória em SQL de 6.194 candidaturas

AUTOR
Charliton Nogueira

DATA
Outubro de 2026

FERRAMENTA
SQL (SQLite)

FONTE
Kaggle (taweilo)

TÉCNICAS
CTEs, funções de janela, estatística em SQL

Resumo

Dos 6.194 candidatos da base, 900 foram admitidos, o que dá uma taxa geral de 14,5%. As notas são o que mais distingue esse grupo. Entre os admitidos, o GMAT médio é de 692,7 pontos e o GPA de 3,35; entre os demais, 644,0 e 3,23. Nacionalidade, área de graduação e anos de experiência quase não mudam a chance de entrar.

Gênero e raça mostram outro quadro. As mulheres tiveram taxa de admissão de 20,0%, contra 11,4% dos homens, e entraram com notas um pouco menores. Candidatos negros e hispânicos foram admitidos em 8,7% e 10,4% dos casos, bem abaixo dos 16,8% registrados entre candidatos brancos, embora os grupos cheguem com as mesmas notas médias.

1. Objetivo

O trabalho responde a onze perguntas de negócio sobre o processo seletivo de um programa de MBA: quem se candidata, quem é aprovado e quais características acompanham a aprovação. Todas as respostas foram obtidas com consultas SQL sobre um banco SQLite. O foco é descritivo; o estudo não tenta prever a admissão nem estabelecer causa e efeito.

2. Base de dados

A base tem uma tabela, `mba`, com 6.194 linhas e 10 colunas. Cada linha é uma candidatura, identificada por `application_id`, sem duplicidades. As variáveis cobrem gênero, nacionalidade (`international`, 0 ou 1), GPA (escala até 4,0), área de graduação (`major`), raça, GMAT (até 800 pontos), anos de experiência, indústria de atuação anterior e o status de admissão.

Segundo a página do dataset no Kaggle, os dados são sintéticos, gerados a partir das estatísticas divulgadas da turma de 2025 da Wharton. Isso não invalida o exercício, mas impede que os resultados sejam lidos como retrato de um processo seletivo real.

Diagnóstico e decisões de tratamento

Antes de responder às perguntas, fiz um perfil de cada coluna: contagem de nulos, valores distintos, mínimos e máximos. Esse diagnóstico levou a quatro decisões.

- **Nulos em `admission`.** As 5.194 linhas vazias não são dados faltantes: a documentação do dataset indica que representam candidatos recusados. Tratei esses nulos como "não admitido".

- **Lista de espera.** Os 100 candidatos em *Waitlist* não têm a vaga garantida, então foram contados como não admitidos. Admitido é apenas quem tem status *Admit*. Testei a alternativa (contar a lista de espera como admissão): as taxas sobem 1,6 ponto percentual na média, entre 1 e 2 pontos na maioria dos grupos, e nenhuma das comparações deste relatório muda de sentido.
- **Nulos em `race`.** Cruzando com `international`, as 1.842 linhas sem raça coincidem exatamente com os candidatos internacionais. Em vez de descartá-las, mantive esses candidatos como uma categoria própria, para não perder 30% da base nas análises por raça.
- **Códigos numéricos.** A coluna `international` usa 0 e 1. Converti para "Nacional" e "Internacional" nas saídas, para que as tabelas possam ir direto para um relatório ou dashboard.

3. Abordagem técnica

Todas as respostas foram calculadas em SQL, sem exportar dados para outra ferramenta. Isso incluiu as medidas estatísticas, que o SQLite não oferece prontas. Os trechos abaixo mostram as soluções usadas nos pontos que exigiam mais cuidado. As consultas completas estão em `mba.sql`.

Taxa de admissão por grupo e a armadilha do NULL

A taxa de admissão precisa de dois números na mesma linha: admitidos (numerador) e todos os candidatos do grupo (denominador). Um filtro `WHERE admission = 'Admit'` eliminaria o denominador. Por isso usei agregação condicional, que filtra apenas o numerador:

```
SELECT
    CASE WHEN international = 1 THEN 'Internacional' ELSE 'Nacional' END AS nacionalidade,
    COUNT(*) AS qtd_candidatos,
    SUM(CASE WHEN admission = 'Admit' THEN 1 ELSE 0 END) AS qtd_admitidos,
    ROUND(100.0 * SUM(CASE WHEN admission = 'Admit' THEN 1 ELSE 0 END)
          / COUNT(*), 2) AS taxa_admissao
FROM mba
GROUP BY international;
```

O `ELSE 0` é essencial. Uma versão mais curta, `AVG(admission = 'Admit')`, devolve NULL quando `admission` é nulo, e o `AVG` ignora esses casos. O resultado seria uma taxa geral de 90% (900 admitidos sobre 1.000 linhas preenchidas), em vez dos 14,5% corretos. O `100.0` com casa decimal evita a divisão inteira, que arredondaria tudo para zero.

Percentual do total com função de janela

Na distribuição dos candidatos, o percentual de cada categoria foi calculado com uma função de janela aplicada sobre a agregação. O `SUM(COUNT(*)) OVER ()` devolve o total geral em todas as linhas, sem subconsulta:

```
SELECT gender, COUNT(*) AS qtd,
       ROUND(100.0 * COUNT(*) / SUM(COUNT(*)) OVER (), 2) AS percentual
FROM mba
GROUP BY gender;
```

Quartis e mediana sem função pronta

O SQLite não tem `PERCENTILE_CONT`. Numerei as linhas de cada grupo em ordem crescente com `ROW_NUMBER()` e selecionei as posições correspondentes a 25%, 50% e 75%. Para a mediana, a média das duas posições centrais trata corretamente grupos com quantidade par de registros:

```
WITH ordenado AS (
    SELECT gpa,
           ROW_NUMBER() OVER (PARTITION BY international ORDER BY gpa) AS posicao,
           COUNT(*)     OVER (PARTITION BY international)              AS qtd
    FROM mba
)
SELECT AVG(CASE WHEN posicao IN ((qtd + 1) / 2, (qtd + 2) / 2) THEN gpa END) AS mediana
FROM ordenado;
```

Correlação de Pearson em SQL

O coeficiente de Pearson é a covariância dividida pelo produto dos desvios padrão. Escrevendo as duas medidas em termos de médias, o cálculo cabe numa única consulta. Usei a mesma fórmula para GPA × GMAT e para experiência × admissão, nesse caso com a admissão codificada como 0 ou 1 (correlação ponto-bisserial):

```
SELECT ROUND(
    (AVG(gpa * gmat) - AVG(gpa) * AVG(gmat))
    / (SQRT(AVG(gpa * gpa)   - AVG(gpa)  * AVG(gpa))
     * SQRT(AVG(gmat * gmat) - AVG(gmat) * AVG(gmat))), 2) AS pearson
FROM mba
WHERE admission = 'Admit';
```

Teste t de Welch com CTEs

Para testar se as médias de nacionais e internacionais diferem, escolhi o teste de Welch, que não supõe variâncias iguais entre os grupos. A primeira CTE calcula tamanho, média e variância amostral (com n − 1) de cada grupo; em seguida, os dois grupos são colocados lado a lado para aplicar a fórmula. Com amostras grandes, |t| > 1,96 indica diferença significativa a 5%:

```
WITH estatisticas AS (
    SELECT international, COUNT(*) AS n, AVG(gpa) AS media,
           (SUM(gpa * gpa) - COUNT(*) * AVG(gpa) * AVG(gpa)) / (COUNT(*) - 1) AS variancia
    FROM mba
    GROUP BY international
)
SELECT (i.media - n.media) / SQRT(i.variancia / i.n + n.variancia / n.n) AS estatistica_t
FROM estatisticas i, estatisticas n
WHERE i.international = 1 AND n.international = 0;
```

Comparação lado a lado com agregação condicional

Para comparar as notas de homens e mulheres, coloquei os dois gêneros em colunas com `AVG(CASE WHEN ... THEN gpa END)`. Sem o `ELSE`, as linhas do outro gênero viram NULL e ficam fora da média, que é exatamente o comportamento desejado aqui. Com as duas médias na mesma linha, a diferença percentual e a regra dos 5% saem na própria consulta.

Validação

Conferi os resultados estatísticos recalculando correlações, médias, desvios padrão e estatísticas t em Python, com a biblioteca padrão. Todos os valores coincidiram com os obtidos em SQL.

4. Resultados

4.1 Perfil dos candidatos

A base é majoritariamente masculina (63,7%) e nacional (70,3%). Humanities é a graduação mais comum, com 40,1%, e STEM e Business dividem o restante quase igualmente. Entre os nacionais, a raça mais frequente é a branca, seguida da asiática.

Tabela 1. **Perfil dos candidatos**

Variável	Categoria	Candidatos	%
Gênero	Masculino	3.943	63,7
	Feminino	2.251	36,3
Nacionalidade	Nacional	4.352	70,3
	Internacional	1.842	29,7
Graduação	Humanities	2.481	40,1
	STEM	1.875	30,3
	Business	1.838	29,7
Raça (nacionais)	Branca	1.456	23,5
	Asiática	1.147	18,5
	Negra	916	14,8
	Hispânica	596	9,6
	Outra	237	3,8

Percentuais calculados sobre o total de 6.194 candidatos.

4.2 Candidatos nacionais e internacionais

A nacionalidade não pesa na admissão. Os internacionais foram aprovados em 15,1% dos casos e os nacionais em 14,3%, uma diferença inferior a um ponto percentual. As notas médias também são praticamente iguais: GPA de 3,24 contra 3,25 e GMAT de 650,0 contra 651,6. Os quartis coincidem e os desvios padrão ficam na mesma ordem nos dois grupos.

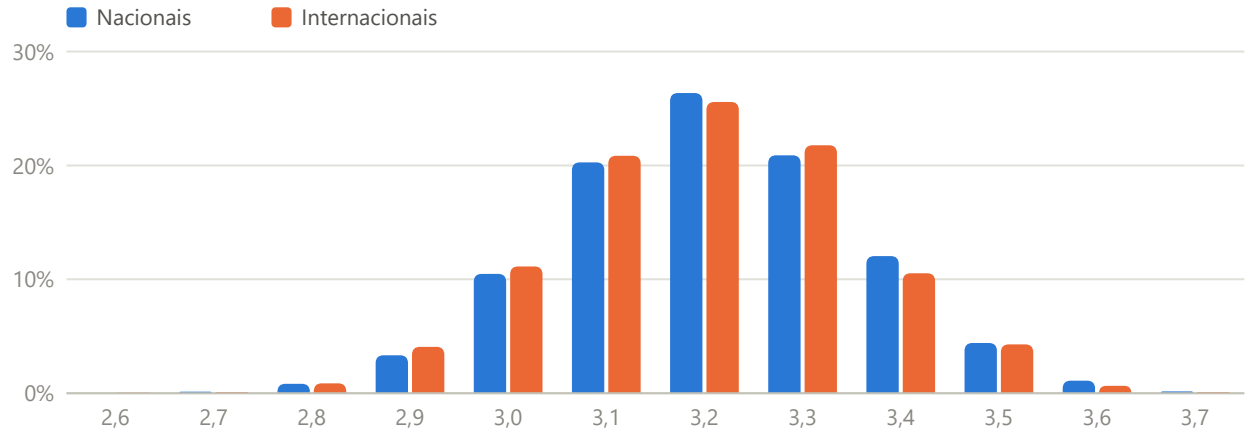
O teste t de Welch aponta diferença estatisticamente significativa no GPA ($t = -2{,}25$; $p \approx 0{,}02$), mas não no GMAT ($t = -1{,}17$). A diferença de GPA, porém, é de um centésimo de ponto. Com milhares de observações, o teste detecta diferenças desse tamanho, que não têm consequência prática. A Figura 1 mostra que as duas distribuições praticamente se sobrepõem.

Tabela 2. **Nacionalidade: admissão, notas e teste t**

Indicador	Nacionais	Internacionais	Estatística t
Candidatos	4.352	1.842	
Taxa de admissão	14,3%	15,1%	
GPA médio	3,25	3,24	−2,25
GMAT médio	651,6	650,0	−1,17
Desvio padrão do GPA	0,15	0,15	
Desvio padrão do GMAT	49,5	48,8	

Teste t de Welch. Com amostras deste tamanho, |t| > 1,96 indica diferença significativa a 5%.

Figura 1. **Distribuição do GPA por faixa, em % de cada grupo**



Cada faixa começa no valor indicado (3,2 = de 3,20 a 3,29).

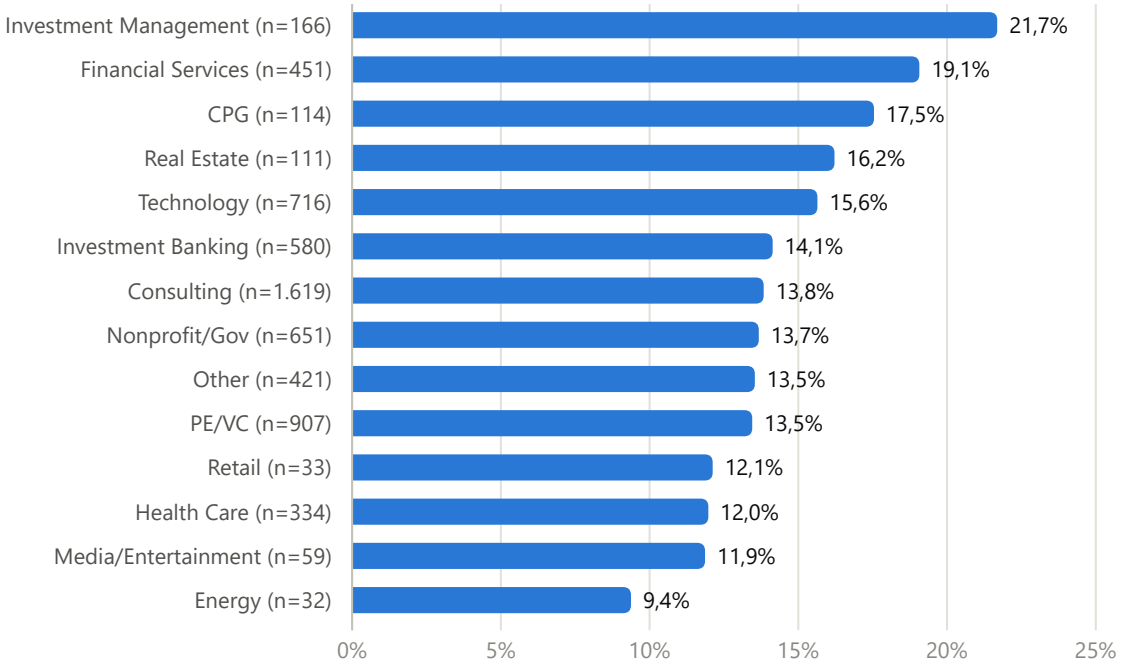
4.3 Relação entre GPA e GMAT

Entre os admitidos, o coeficiente de Pearson entre GPA e GMAT é de 0,52, o que indica uma relação positiva moderada: quem tem GPA mais alto tende a ter GMAT mais alto. Na base completa, o coeficiente sobe para 0,58. A queda entre os admitidos é esperada, porque a seleção concentra o grupo nas notas mais altas e reduz a variação das duas medidas.

4.4 Indústria de atuação

Investment Management tem a maior taxa de admissão, 21,7%, seguida de Financial Services (19,1%) e CPG (17,5%). Consulting, o setor com mais candidatos (1.619), fica em 13,8%, próximo da média geral. As menores taxas aparecem em Health Care (12,0%), Media/Entertainment (11,9%) e Energy (9,4%). Os setores ligados a finanças, portanto, saem na frente, mas Retail e Energy têm tão poucos candidatos que suas posições no ranking não são confiáveis.

Figura 2. **Taxa de admissão por indústria de atuação anterior**



Retail e Energy têm menos de 50 candidatos; as taxas desses dois grupos oscilam muito com poucos casos.

4.5 Experiência profissional

Os anos de experiência não têm relação com a admissão. O coeficiente de Pearson entre experiência e admissão, codificada como 0 ou 1, é de 0,01. A taxa fica entre 13% e 15% para quem tem de 3 a 7 anos de experiência, faixa que concentra 98% dos candidatos. A comparação por gênero confirma o resultado: aprovados e não aprovados têm, em média, cerca de cinco anos de experiência, com diferença de poucos centésimos.

Tabela 3. **Experiência profissional média (anos)**

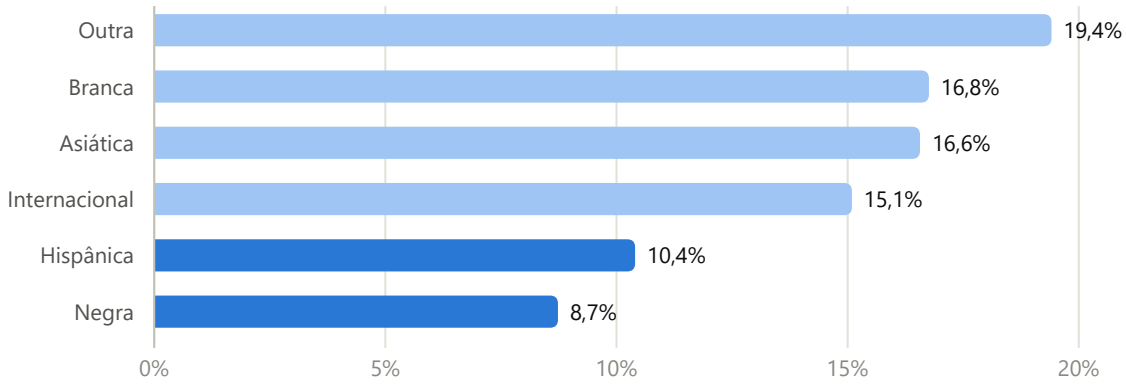
Gênero	Aprovados	Não aprovados	Diferença
Feminino	5,06	5,02	+0,04
Masculino	5,03	5,01	+0,02

4.6 Raça e etnia

A probabilidade condicional de admissão varia bastante entre os grupos. Candidatos da categoria Outra têm a maior taxa (19,4%), seguidos de brancos (16,8%) e asiáticos (16,6%). Hispânicos (10,4%) e negros (8,7%) ficam bem abaixo.

A diferença não vem das notas de candidatura: os seis grupos chegam com GPA médio entre 3,24 e 3,26 e GMAT entre 650 e 653. Entre os admitidos, os candidatos negros e hispânicos têm as maiores médias (GMAT de 699,0 e 699,5, contra 692,4 dos brancos). Isso indica que, para esses grupos, a nota exigida na prática foi mais alta.

Figura 3. **Taxa de admissão por raça/etnia**



Taxa = admitidos ÷ candidatos de cada grupo. O dataset não registra raça para candidatos internacionais.

4.7 Gênero

A pergunta proposta considera irrelevante uma diferença de notas inferior a 5%. Por esse critério, não há diferença de gênero nas notas. Na base completa, as médias de homens e mulheres diferem menos de 0,5%. Entre os admitidos, as mulheres têm GPA 1,5% menor e GMAT 2,8% menor, ainda abaixo do limite.

A taxa de admissão, por outro lado, é bem diferente: 20,0% para mulheres e 11,4% para homens. O programa admitiu exatamente 450 pessoas de cada gênero, mesmo recebendo 1,75 candidato homem para cada mulher. O resultado é coerente com uma meta de turma equilibrada. Os dados não permitem afirmar se essa meta existe, mas o padrão é claro e merece registro.

Tabela 4. **Notas médias e admissão por gênero**

Grupo	Indicador	Feminino	Masculino	Diferença
Todos	GPA	3,25	3,25	−0,2%
Todos	GMAT	649,6	651,9	−0,4%
Admitidos	GPA	3,33	3,38	−1,5%
Admitidos	GMAT	682,8	702,6	−2,8%
Todos	Taxa de admissão	20,0%	11,4%	
Todos	Admitidos	450	450	

Diferença = (Feminino − Masculino) ÷ Masculino.

5. Conclusões

GPA e GMAT são as variáveis que mais acompanham a aprovação. A diferença de quase 50 pontos no GMAT médio entre admitidos e não admitidos é o maior contraste observado na base. Nacionalidade, área de graduação e experiência profissional, que costumam ser apontadas como diferenciais, praticamente não alteram a taxa de admissão.

Gênero e raça são os pontos que pedem atenção. As mulheres são admitidas em proporção bem maior que os homens, com notas um pouco menores, dentro da margem de 5% definida como irrelevante. Candidatos negros têm cerca de metade da chance de admissão de brancos e asiáticos, e os hispânicos ficam pouco acima disso, apesar de os grupos chegarem com as mesmas notas. Os negros e hispânicos que entram têm médias acima dos outros grupos. Num processo real, esses dois achados seriam o ponto de partida para revisar os critérios de seleção.

6. Limitações

- Os dados são sintéticos. Os padrões refletem a forma como a base foi gerada e não necessariamente o comportamento de um comitê de admissão real.
- A análise é descritiva. Diferenças entre grupos não provam causa, porque outras variáveis não observadas, como entrevistas, cartas e redação, podem explicar parte delas.
- A lista de espera foi tratada como não admissão. Como mostrado na seção 2, contá-la como admissão eleva as taxas sem alterar as conclusões.
- O p-valor do teste t foi aproximado pela distribuição normal, adequada para amostras deste tamanho. O SQLite não calcula p-valores diretamente.

7. Técnicas por pergunta

Tabela 5. **Recursos de SQL usados em cada pergunta**

Pergunta	Tema	Recursos de SQL
1	Perfil dos candidatos	GROUP BY, COUNT, SUM() OVER (), COALESCE
2	Admissão por nacionalidade	CASE WHEN dentro de SUM, taxa condicional
3	Médias por nacionalidade	AVG, ROUND, GROUP BY com expressão
4	Distribuições	CTE, UNION ALL, ROW_NUMBER() OVER (PARTITION BY), quartis, histograma
5	Teste de hipóteses	CTE, variância amostral, autojunção, teste t de Welch
6	GPA × GMAT	Correlação de Pearson com AVG e SQRT
7	Admissão por indústria	Taxa condicional, ORDER BY
8	Experiência × admissão	CTE, variável 0/1, correlação ponto-bisserial
9	Admissão por raça	Probabilidade condicional, COALESCE
10	Gênero e notas	CTE, AVG(CASE WHEN), diferença relativa, regra de decisão com CASE
11	Experiência por gênero	GROUP BY com duas dimensões

8. Reprodução

O banco `mba-admission.db` é gerado pelo script `gerar_banco.py` a partir do arquivo `MBA.csv`, disponível no Kaggle. As consultas de todas as perguntas estão em `mba.sql`, na mesma ordem deste relatório, e podem ser executadas em qualquer cliente SQLite, como DB Browser for SQLite ou DBeaver.